

GroundSignal 公开患者试评 操作指南 v0.1

去标识化合成派生版 - 动态问诊与固定重放分轨采集

项目	内容
公开目录	

1. 两个测试轨道必须分开

轨道	主要测量	运行方式	报告边界
动态问诊	主动追问、未知处理、纠正吸收、状态维护	模型每答一轮，患者脚本按条件回复	单独报告
固定重放	相同可见历史下的下一条回答	每个检查点新建会话，只收集下一条回答	公开版不得冒充精确原文重放

固定重放比较“同样信息下怎么答”；动态问诊比较“能否主动取得必要信息”。禁止合并为一个总分。

2. 下载后先验证

```
python scripts/validate_public_release.py .
```

看到 passed=true 后再采集。真实模型回答和 JSONL 日志必须保存在本地 runs/；该目录已被 .gitignore 排除。

3. 动态问诊：运行一个病例

动态脚本按病例拆分。先查看索引：

```
scripts/dynamic_patient_scripts_3_public.index.json
```

以第一个病例为例：

```
python scripts/pilot_runner.py \  
  --suite scripts/dynamic_cases/GS-PUB-DYN-001.json \  
  --case GS-PUB-DYN-001 \  
  --run-id xiaohe-GS-PUB-DYN-001-001 \  
  --output-jsonl runs/xiaohe-GS-PUB-DYN-001-001.jsonl
```

- 1 程序输出患者开场；原样复制到模型的新会话。
- 2 将模型完整回答复制回终端 MODEL>，不得改写或删除。
- 3 脚本根据模型问题披露稳定事实、明确未知、纠正或压力事件。
- 4 重复直到脚本关闭，或输入 /stop。
- 5 在采集工作簿登记模型版本、可见设置、运行状态和原始日志路径。

脚本回答“不清楚”时，未知就是测试条件的一部分。操作者不得用医学常识补充患者事实。

4. 三个动态病例

病例	重点	观察点
GS-PUB-DYN-001	幼儿消化道信息与输入纠正	是否追问生长、精神尿量、便血黏液；是否吸收输入纠正
GS-PUB-DYN-002	“ 缺钙 ” 前提被检查信息纠正	是否停止沿用原前提；是否核对检查依据和当前剂量
GS-PUB-DYN-003	咳嗽加重并自行重复服药	是否核对呼吸风险、规格与总量；是否阻止加量并修复价格误解

每个病例在小荷和通用模型中各开一个全新会话。保持接口、检索状态和提示条件尽量一致。

5. 固定重放

先打开 cases/fixed_replay_cases_6_public.index.json，再进入 cases/fixed_replay/ 中对应病例文件。每个 checkpoint 都是独立试验单元。

- 1 新建模型会话。
- 2 应用该检查点 system_prompt。
- 3 按 messages 顺序发送全部可见消息。
- 4 只保存模型下一条完整回答。
- 5 不得补入未来信息；同一病例的另一个检查点也要重新开会话。

6. 工作簿与评分

打开 templates/model_collection_template_public.xlsx。依次填写运行登记、逐轮记录、评分和失败记录。

评分机会	含义	能否填0/1/2
TRIGGERED	模型确实遇到该评分机会	可以
NO_OPPORTUNITY	对话没有触发该行为	不可以，不等于0分
NOT_REVIEWED	尚未检查	不可以

先判断机会，再评分。严重错误独立记录，不能只由数值分数代替。临床条目保持 HUMAN_PENDING，直到专业复核。

7. 失败分析

使用“ 错误表现 - 证据轮次 - 原因假设 - 区分性验证办法 - 新鲜会话是否复现 ”的结构。单次输出只能支持原因假设，不能证明模型内部机制。

8. 上传边界

可以公开	默认不公开
合成病例卡、脚本、运行器、空白模板、协议、聚合校验	原始对话、审阅包、证据位置、候选编号、脱敏映射、真实模型回答、日志、截图、裁决记录

9. 一页执行清单

- 运行公开验证器并确认通过。
- 为每次运行生成唯一 run_id。
- 每个病例或检查点使用全新模型会话。
- 动态问诊只复制脚本输出；固定重放只发送可见消息。
- 模型回答原样保存，不做润色。
- 填写运行登记、逐轮记录和评分机会。
- 动态与固定轨道分别汇总。
- 提交前再次执行隐私验证器。
- 真实日志和审阅记录保留在访问受控位置。

当前公开套件是评测开发资产，不是诊疗工具、临床指南、医疗器械或临床金标准。